

Zasnova sistema RAG za odgovarjanje na vprašanja

Projektna naloga pri predmetu Iskanje in ekstrakcija podatkov s spleta

V tretji projektni nalogi smo razvili sistem Retrieval-Augmented Generation (RAG). Ta preko spletnega vmesnika omogoča odgovarjanje na vprašanja z uporabo konteksta (prek semantičnega iskanja po vsebini pridobljeni v sklopu druge naloge) in brez konteksta (samo na podlagi generativnega modela). Uporabili smo FastAPI za vzpostavitev lokalnega strežnika ter Ollama za povezavo z izbranim jezikovnim modelom GaMS-9B-Instruct.

1. POVZETEK IMPLEMENTACIJE

1.1 Uporabljeni model za vektorsko predstavitev in jezikovni model

V sklopu naloge smo za generiranje vektorskih predstavitev segmentov uporabili LaBSE, ki podpira tudi slovenski jezik. Tega smo uporabili že v drugi nalogi, kjer smo ga primerjali s modelom SloBERTa in ugotovili, da je pri poizvedbah dosegal nekoliko boljše rezultate. V okviru tretje naloge smo LaBSE uporabili za pretvorbo vprašanj uporabnikov v vektorsko predstavitev, ki smo jo nato primerjali z že shranjenimi vektorji segmentov v podatkovni bazi.

Za generativni del smo uporabili odprtokodno platformo Ollama, ki omogoča lokalno poganjanje velikih jezikovnih modelov. V sistem smo integrirali jezikovni model GaMS-9B-Instruct-GGUF:Q6_K, ki je prilagojen za odgovarjanje na vprašanja na podlagi navodil. Model se uporablja tako za generiranje odgovorov z uporabo konteksta v okviru sistema RAG, kjer prejme relevantne dokumente iz baze, kot tudi za odgovore brez konteksta, kjer generira odgovor zgolj na podlagi vprašanja.

1.2 Struktura in shranjevanje dokumentov

Za namen iskanja relevantnih vsebin smo vse dokumente strukturirali na ravni logičnih segmentov, ki so bili določeni že v fazi priprave podatkov v drugi nalogi. Segmenti predstavljajo osnovno enoto za iskanje in obsegajo tri različne tipe: naslovi člankov, odstavki iz besedila novic ter komentarji. Segmenti so bili nato shranjeni v PostgreSQL bazo v tabelo `page_segment`, kjer vsak vnos predstavlja en segment. Za omogočanje učinkovitega iskanja po semantični podobnosti smo bazo razširili z razširitvijo `pgvector`, ki omogoča shranjevanje in iskanje po vektorskih predstavitvah. Vsak segment ima poleg besedilne vsebine še vektorsko predstavitev v polju `embedding`, generirano z modelom LaBSE. Takšna struktura omogoča hitro in učinkovito iskanje relevantnih vsebin za posamezna vprašanja, saj lahko nad vektorskimi predstavitvami izvajamo iskanje top-k najbližjih rezultatov.

1.3 Integracija iskalnega in generativnega dela sistema

Uporabnik lahko z aplikacijo komunicira prek REST API-ja, s POST zahtevkom ali pa preko uporabniškega vmesnika, kjer vprašanje vnese neposredno v obrazec. V obeh primerih se ob oddaji vprašanja preveri, ali je izbrana uporaba RAG pristopa. Če je RAG vključen, sistem izvede generacijo vektorske predstavitve vprašanja z uporabo modela LaBSE. Nato se izvede SQL poizvedba nad `pgvector` bazo, kjer se izberejo najbližji segmenti (top-k glede na podobnost). Ti segmenti se nato sestavijo v kontekst, ki se jezikovnemu modelu posreduje skupaj z vprašanjem. Če je RAG izklopljen,

model dobi le vprašanje brez dodatnega konteksta. Ko model sestavi celoten odgovor, se ta posreduje nazaj uporabniku v JSON obliki ali pa se prikaže v uporabniškem vmesniku.

1.4 Dodatna orodja in uporabljene knjižnice

Poleg do sedaj omenjenih orodij in knjižnic, smo za delovanje sistema uporabili:

- Uvicorn: ASGI strežnik, uporabljen za zagon FastAPI aplikacije. Omogoča lokalno gostovanje z nizko latenco in podporo za asinhrono izvajanje.
- SQLAlchemy: objektno-relacijski vmesnik, ki omogoča komunikacijo z PostgreSQL bazo. Uporabljen za vzpostavitev povezave, izvajanje SQL poizvedb in delo s sejami.
- Sentence-transformers: knjižnica za enostavno uporabo modela LaBSE pri generiranju vektorskih predstavitev besedil.

2. OCENJEVANJE SISTEMA

2.1 Obdelava podatkov

V drugi projektni nalogi smo najprej izvedli čiščenje HTML vsebine, tako da smo odstranili vse nerelevantne elemente, kot so obrazci, oglasi in noge strani. Nato smo iz vsebine izluščili zgolj ključne informacije: naslov članka, celotno besedilo članka ter vse uporabniške komentarje. Za vsak segment smo shranili tudi metapodatke, kot so vrsta segmenta (naslov, odstavek ali komentar), čas objave, avtor in kategorija vsebine. Po pridobitvi podatkov smo besedilo razdelili v manjše segmente glede na vrsto vsebine. Članke smo segmentirali po odstavkih in jih analizirali glede na dolžino: krajše odstavke (pod 50 znakov) smo združili z naslednjimi, dokler nismo presegli spodnje meje, medtem ko smo pri presežku nad 500 znaki prekinili segment in začeli novega. Komentarji in naslovi so bili shranjeni kot ločeni segmenti brez dodatne delitve, saj so že bili krajši.

Pri evalvaciji sistema se je pokazalo, da so bili najkoristnejši segmenti z vsebino člankov, saj so pogosto vsebovali ključne informacije, ki so modelu omogočile natančno in kontekstualno ustrezno generiranje odgovorov. Nasprotno pa so se komentarji izkazali za vsebinsko šibkejši in so prispevali manj uporaben ali zavajajoč kontekst. Kakovost očiščenega besedila se je izkazala kot zadovoljiva, prav tako pa se je kot zelo smiselna pokazala delitev segmentov glede na vrsto segmenta, saj nam je omogočila, da smo pri končni implementaciji preprosto filtrirali in uporabili le segmente člankov. Slabost se je pokazala predvsem pri dolžini segmentov. Med testiranjem se je izkazalo, da krajši segmenti omogočajo hitrejšo procesiranje in bolj tekoče odgovarjanje, zato bi bili lahko naši segmenti nekoliko krajši, vendar še vedno dovolj dolgi, da ohranijo širši kontekst.

2.2 Iskanje podatkov

Za vsako poizvedbo smo uporabili iskanje po vektorski podobnosti in pridobili top 3 najbližje segmente iz baze. Na začetku smo preizkušali tudi nastavitve top 5, vendar se je izkazalo, da dodatna dva segmenta nista bistveno izboljšala kakovosti odgovorov, hkrati pa se je čas generacije odgovora občutno podaljšal. Glede na daljšo dolžino segmentov in manj zmogljivo strojno opremo (posebej pri lokalnem poganjanju LLM prek Ollama), se je top 3 izkazal kot dober kompromis med odzivnostjo in kvaliteto konteksta. Ustreznost segmentov smo med testiranjem sistema ocenjevali ročno. Za vsako poizvedbo smo preverili vsebino pridobljenih segmentov in ocenili, ali se smiselno navezujejo na zastavljeno vprašanje. V večini primerov so bili rezultati ustrezni, saj smo že v drugi nalogi uporabili metodo segmentacije, ki ohranja smiselno strukturo vsebine.

Kakovost iskanja ima vpliv na delovanje RAG sistema, saj določa, kakšen kontekst bo generativni model prejel. Če so pridobljeni segmenti neustrezni ali preveč splošni, lahko model poda netočen, nerelevanten ali zavajajoč odgovor.

2.3 Evalvacija sistema

Za evalvacijo sistema smo pripravili nabor vprašanj, ki so vključevala podrobno definirana ali nejasno zastavljena vprašanja. Sistem smo testirali v obeh načinih delovanja, z uporabo RAG in brez njega. Ugotovili smo, da so odgovori, ustvarjeni z RAG pristopom, vsebinsko bogatejši, utemeljeni na realnih podatkih in bolj kontekstualno ustrezni. Odgovori brez RAG so večkrat bili površni ali vsebovali napačne oz. izmišljene informacije. Še posebej pri slabo definiranih vprašanjih se je pokazalo, da sistem brez konteksta slabše oz. namišljeno navaja odgovore. V nasprotju s tem pa je RAG sistem tudi pri dvoumnih vprašanjih generiral bolj smiselne odgovore, ki so bili povezani z vsebino iz baze.

Poizvedba	Odgovor brez RAG	Odgovor z RAG	Komentar
Kdaj bi Butch Wilmore in Suni Williams morala potovati domov?	24. aprila 2015, dan pred misijo Sojuz TMA-16.	Butch Wilmore in Suni Williams sta bila sprva načrtovala potovanje nazaj na Zemljo 26. junija, vendar so to možnost prečrtali zaradi tehničnih težav z vesoljskim plovilom Starliner. Njun obisk na Mednarodni vesoljski postaji se bo tako zavlekel vsaj do sredine julija.	Odgovor brez RAG je napačen in nesmiseln, saj navaja leto 2015, ki z dogodkom ni povezano. Odgovor z RAG pa je aktualen in dejansko povzema pravo novico iz konteksta.
Kakšne zahteve so postavili beloruski kiberpartizani po napadu na železniški sistem?	Napadalci so v zameno za nedelovanje sistema zahtevali objavo imen ruskih vojakov, ubitih med invazijo.	Za izročitev dešifrirnih ključev zahtevajo izpustitev 50 političnih zapornikov in odhod ruskih sil iz Belorusije.	Odgovor brez RAG je delno smiseln, vendar splošen in brez podrobnosti. RAG odgovor vsebuje konkretnije in bolj natančne informacije.
Koliko političnih zapornikov želijo beloruski kiberpartizani izpustiti v zameno za dešifrirne ključe?	14 političnih zapornikov.	50.	Odgovor brez RAG navaja napačno številko, medtem ko odgovor z RAG poda pravilen podatek.
Kako Chris Anderson v knjigi Izdelovalci uporabi prispodobo frnikol in peska za razlago delovanja dolgega repa v digitalni ekonomiji?	V svoji knjigi "Izdelovalci" Chris Anderson uporablja slikovit prikaz z igro s frnikolami, da bi pojasnil koncept dolgega repa. V tem primeru je pesek kot celoten trg izdelkov ali storitev, ki so dostopni v digitalni ekonomiji. Frnikole predstavljajo posamezne artikle na tem trgu. Anderson pravi, da če vržete veliko frnikol v vrečo in jih razporedite po velikem kupu peska, bodo nekatere padle zelo blizu skupaj, mnoge pa bodo pristale daleč narazen. To ilustrira koncept dolgega repa v praksi: čeprav je veliko izdelkov manj prodajanih (podobno kot frnikole, ki padejo tesno skupaj), obstaja veliko število izdelkov, ki se prodajajo zelo redko (kot frnikole, ki pristanejo daleč narazen). Ta primer pomaga razložiti, kako digitalna ekonomija omogoča izjemno širok spekter možnosti in kako lahko celo zelo specifični ali nišni izdelki najdejo svojo skupino kupcev, ne da bi ogrozili	V knjigi "Izdelovalci" avtor Chris Anderson uporabi zanimivo prispodobo za opis ideje dolgega repa, ki jo je predstavil že v svoji prejšnji knjigi. Prispodoba prikazuje kozarec z nekaj velikimi frnikolami (ki simbolizirajo velike korporacije in njihove tržne deleže) ter veliko peska (ki predstavlja manjšinske izdelke, ki so del dolgega repa). Anderson poudarja, da kljub temu, da so večji deli kozarca zapolnjeni z velikimi frnikolami, ostane še vedno dosti nezaseden prostor za manjše in bolj specifične izdelke. Tako trdi, da je v digitalni ekonomiji dovolj prostora tudi za tiste, ki niso del največjih in najbolj dominantnih podjetij na trgu. Ta prispodoba pomaga razumeti, kako lahko majhna podjetja ali celo posamezniki uspevajo s ponudbo bolj specifičnih izdelkov ali storitev, ki jih večji igralci morda ne pokrivajo učinkovito.	Odgovor brez RAG omeni prispodobo z igro s frnikolami in peskom, vendar napačno razloži pomen posameznih elementov.

	prevladujoče tržne deleže glavnih igralcev.		
Zakaj nevladne organizacije ob razkritju naprave podjetja Datong PLC omenjajo izraz 'fishing expedition'?	Ta vrsta vožnje se pogosto uporablja pri iskanju ribolovnih mest, kjer je veliko rib. Podobno tudi vlade in zasebna podjetja iščejo mesta z velikimi količinami surovin s pomočjo satelitskih posnetkov ali letalskih fotografij.	Zaradi zmožnosti, da policija s to napravo prisluškuje vsem osebam na določenem geografskem območju, ne glede na to ali jih utemeljeno sumi priprave oz. izvršitve kaznivega dejanja, kar je ustavni kriterij za poseg v zasebnost.	Odgovor brez RAG napačno interpretira pomen izraza fishing expedition, saj uporabi dobesedni pomen izraza, a v tem kontekstu neustrezen.
Kaj se je zgodilo med drugo slovensko revolucijo leta 2015?	Leta 2015 so v Sloveniji zopet odkrili velike količine urana, ki ga za svoja jedrska orožja nujno potrebujejo Združene države Amerike. Zaradi tega je bil slovenski narod ponovno okupiran in razdeljen na fašistične in komunistične enote.	Druge slovenske revolucije ni bilo, so pa bile napetosti v državi in družbi visoke že od osamosvojitve. Zgodovino zadnjih desetletij zaznamuje politična nestabilnost, korupcijski škandali in gospodarska kriza. Leta 2015 je bila Slovenija še vedno čvrsto zasidrana v demokratični ureditvi brez revolucionarnih sprememb.	Na napačno zastavljeno vprašanje, odgovor brez RAG vsebuje popolnoma napačne in izmišljene informacije. Čeprav iskan niz ni bil prisoten v pridobljenih segmentih, pa je sistem preko RAG pristopa dal vsebinsko pravičen odgovor.
Kaj je to?	To je kriptogram. Kriptogram izhaja iz grške besede kryptós, kar pomeni skrivno ali skrito in graphé, pisanje oz. opisovati. Gre za način zapisovanja besedila s simboli, tako da običajen bralec ne more razumeti sporočila.	To je novica o menjavi strežnika Slo-Techa.	Na pomanjkljivo vprašanje, je RAG sistem iz baze pridobil specifičen segment in odgovoril z realno, kontekstualno utemeljitvijo. Brez konteksta pa je model opisoval ne zastavljen pojem.
Kako deluje?	Eterična olja, ki so v šamponu, prodrejo globoko in odstranijo odmrle luske z lasišča. Tako se lase lahko spet očistijo in jih je enostavno umiti.	Virus HIV so raziskovalci "prepričali" tako, da so ga modificirali z genom za CD4 in CCR5 receptorja, ki jih virus sicer uporablja kot vrata v celico gostitelja, s tem pa je bil preoblikovan virus sposoben napasti le tiste celice, ki te receptorje imajo na površini. In ker so rakaste celice prav tako obilno posejane z omenjenimi receptorji, se lahko "preoblečeni" HIV osredotoči samo nanje in jih uničuje.	Tudi tu, je na slabo zastavljeno vprašanje, odgovor brez RAG podal razlago besede, ki v vprašanju ni bila nikjer navedena. RAG pa je kontekstualiziral vprašanje in usmeril jezikovni model v natančen opis, ki ima ustrezno podlago v podatkovni bazi.
Zakaj se to dogaja?	Vse v Vesolju je povezano. Vsa živa bitja, vse materije in energije. Vsaka sprememba na katerem koli nivoju življenja ima posledice za celotno vesoljsko stvarstvo. Tudi ljudje smo del tega velikega sistema – ekosistema. Zgodovina je pokazala, da so se vsa civilizirana bitja, ki so živela pred nami, iztrebila zaradi nespoštovanja narave in njenih zakonov življenja. Vsako živo bitje ima svoje mesto na Zemlji z razlogom – svojo funkcijo. In vsakdo od nas lahko pomaga pri ozdravitvi matere Zemlje,... To ni le dolžnost vsakega posameznika, je tudi njegova pravica do sodelovanja v skupnem boju za ohranitev narave in s tem pravice do življenja na Zemlji. Ne smemo izgubiti upanja! Vsak korak k ozdravitvi naše matere Zemlje nam da novo upanje!	Zaradi človeške lenobe (beri: pomanjkanja razmišljanja). Ko so prvi izdelovalci letal leta 1903 ugotovili, da je treba za polet v zrak napraviti dovolj močen motor in izdelati krilca tako, da se bo to kolo srečalo s tlemi, so bili na dobri poti. A ko so začeli uporabljati tudi propelerje in jih prilagajati letalom, niso razmišljali o tem, kako bi lahko te naprave delovale z različnimi oblikami kril ali trupa. Tako je nastalo veliko modelov, ki so se medsebojno prepletali in bili odvisni drug od drugega. Ko so kasneje ugotovili še, da morajo motorji poganjati propelerje s točno določeno hitrostjo (torej ne samo dovolj močni), je bilo jasno, da bo treba zadevo rešiti na drugačen način. Tako so se leta 1942 odločili za standardizacijo vseh delov letala – od motorjev preko propelerjev do koles in drugih sestavnih delov.	Čeprav je vprašanje zelo odprto in nenatančno, je RAG sistem uspel najti zgodovinski kontekst, ki odgovoru doda smisel. Odgovor brez konteksta je popolnoma nerelevanten.

Tabela 1: Primerjava odgovorov z RAG in brez.